

Análise Preditiva de Óbitos em Acidentes nas Rodovias Federais: Uma Abordagem via Modelos Lineares Generalizados

Lucas Ferraz Macris

Disciplina SME0823 - Prof. Vicente G. Cancho

Instituto de Ciências Matemáticas e de Computação (ICMC-USP)

Resumo

Este documento apresenta a proposta inicial para o trabalho final da disciplina SME0823. O projeto tem como objetivo aplicar Modelos Lineares Generalizados (MLGs) para investigar os fatores associados e prever a ocorrência de vítimas fatais em acidentes nas rodovias federais brasileiras. Utilizando dados abertos da Polícia Rodoviária Federal (PRF), o estudo adota uma estratégia de validação com partição temporal (dados de 2024 para ajuste e 2025 para teste final). O texto delineia a justificativa social e estatística, a unidade de análise, as variáveis selecionadas e a abordagem metodológica baseada na regressão logística (família Binomial com ligação *logit*). Além disso, estabelece as diretrizes de reprodutibilidade por meio de repositório público.

Palavras-chave: Regressão Logística, Acidentes de Trânsito, PRF, Modelagem Preditiva.

1 Introdução e Justificativa

Os acidentes de trânsito configuram um dos maiores desafios para a saúde e a segurança pública no Brasil, resultando em elevados custos sociais e irreparáveis perdas de vidas. A Polícia Rodoviária Federal (PRF) consolida continuamente uma base de dados abertos que detalha os incidentes nas rodovias, permitindo investigações sobre as dinâmicas dos sinistros.

Do ponto de vista social, identificar fatores que elevam o risco de letalidade nas estradas é fundamental para orientar políticas públicas e otimizar a alocação de recursos de fiscalização. Sob a ótica estatística, o problema oferece um cenário ideal para a aplicação de Modelos Lineares Generalizados (MLGs). Lidar com dados de natureza binária (ocorrência ou não de óbito) exige a modelagem correta de probabilidades, além de apresentar desafios reais como a seleção de variáveis preditoras (qualitativas e quantitativas) e o *trade-off* viés-variância na construção de um modelo com alta capacidade preditiva para novos dados.

2 Formulação do Problema e Objetivos

A questão de pesquisa é: **Quais são os principais fatores climáticos, de infraestrutura e da dinâmica da colisão associados à ocorrência de óbitos em acidentes nas rodovias federais, e qual a capacidade de um modelo logístico prever esse desfecho em dados futuros?**

2.1 Unidade de Análise, População e Amostra

A **unidade de análise** é o *acidente de trânsito (ocorrência única)*, agrupado conforme os registros oficiais da PRF. A **população** engloba a totalidade dos acidentes registrados nas rodovias federais sob jurisdição da PRF no Brasil. A **amostra** será composta pelos acidentes ocorridos nos anos de 2024 e 2025, após limpeza, tratamento de dados faltantes (NA) e eliminação de registros inconsistentes. Os dados de 2024 serão destinados à análise exploratória, treinamento e ajuste do modelo, enquanto os registros de 2025 formarão o conjunto de teste para a validação preditiva final.

2.2 Objetivos

Objetivo Geral: Aplicar modelos da classe GLM aos dados reais da PRF para prever a ocorrência de óbitos em acidentes de trânsito, avaliando a capacidade preditiva do modelo em dados futuros.

Objetivos Específicos:

- Aplicar os GLMs (focando no modelo Logístico devido à resposta binária) aos dados reais;
- Realizar análise exploratória e diagnóstico rigoroso dos modelos ajustados;
- Comparar modelos concorrentes usando critérios como AIC, BIC e validação cruzada;
- Avaliar a capacidade preditiva usando o *trade-off* viés-variância;

3 Revisão Bibliográfica

A fundamentação teórica baseia-se na teoria dos Modelos Lineares Generalizados, consolidada por McCullagh & Nelder (1989). Devido à natureza dicotômica da variável resposta, a regressão logística emerge como a principal abordagem, permitindo interpretar o impacto das covariáveis por meio da razão de chances (Collett, 2002). Procedimentos de ajuste e diagnóstico serão conduzidos com base em Paula (2004) e Demetrio (2002). Para a fundamentação dos métodos de validação preditiva, particionamento dos dados e análise do *trade-off* viés-variância, utilizaremos os conceitos de James et al. (2013).

4 Material e Métodos

4.1 Fonte de Dados e Reprodutibilidade

Os dados são de domínio público e obtidos no Portal de Dados Abertos da Polícia Rodoviária Federal, fornecidos sob a licença de Dados Abertos. Para garantir a reprodutibilidade,

um repositório estruturado foi criado contendo os *scripts* computacionais, o qual pode ser acessado no GitHub.

4.2 Modelagem e Dicionário de Variáveis

Assumiremos que a variável resposta (Y), condicionada às preditoras (x), segue uma distribuição da família **Binomial**. O componente sistemático será ligado ao valor esperado da resposta através da função de ligação *logit*.

A Tabela 1 apresenta o dicionário das variáveis selecionadas da base bruta da PRF.

Tabela 1: Dicionário de Variáveis do Modelo

Variável PRF	Papel	Descrição e Transformação Adotada
mortos	Resposta (Y)	Indicadora de letalidade derivada do total de óbitos (1 = Ocorreu óbito; 0 = Sem óbito) (Binária).
tipo_acidente	Preditora (X_1)	Classificação da mecânica do impacto (ex: Colisão frontal, Capotamento, Atropelamento de Pedestre) (Qualitativa Nominal).
condicao_meteorologica	Preditora (X_2)	Clima no momento da ocorrência (ex: Céu Claro, Chuva, Nevoeiro/Névoa) (Qualitativa Nominal).
tipo_pista	Preditora (X_3)	Classificação estrutural da via (ex: Simples, Dupla, Múltipla) (Qualitativa Nominal).
uso_solo	Preditora (X_4)	Natureza do trecho da rodovia (ex: Urbano, Rural) (Qualitativa Nominal).
veiculos	Preditora (X_5)	Total de veículos envolvidos na ocorrência (ex: 1, 2, 3 ou mais veículos) (Quantitativa Discreta).
causa_acidente	Preditora (X_6)	Causa principal presumida do sinistro (ex: Reação tardia do condutor, Velocidade Incompatível, Ingestão de Alcool) (Qualitativa Nominal).

Referências

- Collett, D. (2002). *Modelling Binary Data*. 2^a ed. Chapman & Hall/CRC.
- Demetrio, C. G. B. (2002). *Modelos Lineares Generalizados em Experimentação Agrônômica*. ESALQ/USP.

- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning: with Applications in R*. Springer.
- McCullagh, P., & Nelder, J. A. (1989). *Generalized Linear Models*. 2^a ed. Chapman & Hall/CRC.
- Paula, G. A. (2004). *Modelos de Regressão com Apoio Computacional*. IME/USP.